

投資情報を **AI-Ready** にせよ

AI-Ready データとは何か？ — AI エージェントが金融情報を「使える」ようになると何が起きるのか

いとう @INDX

マケデコ (market-api.dev) / J-Quants コミュニティ

自己紹介と会社紹介

Speaker & Company

伊藤

伊藤 克哉 (いとう かつや)

株式会社 INDX 代表取締役 CEO

- 東京大学 **数学科** → 大学院 **経済学研究科**
- **Preferred Networks** → **三井物産** → 2025 年 **INDX 創業**
- 専門: **機械学習 × クオントゥ金融**
- **AAAI / AAMAS** 等に筆頭著者論文

株式会社 INDX

設立 2025 年 4 月・東京都港区

代表 伊藤 克哉

資金 シードで総額 **1 億円**

日本企業に眠る**非構造データ**を価値に変える
AI & データプラットフォーム。**オンプレミス生成 AI** でデータ主権を守る。

きょうの問い

いとう@INDX

- 私たちは金融データを **AI-Ready** にする仕事をしています。
- きょう話したいのは、2つの素朴な問いです。

2つの問い

1. **AI-Ready データとは何か？** — 「読める」だけで十分なのか。
2. AI エージェントが金融情報を「**使える**」ようになると、いったい**何が起きるのか？**

結論を先に

AI-Ready の本質は「アクセスできる」ことではなく、データが**アウトカム (=リターン)**につながる状態にあること。そこへ至る道には **2つの壁**がある。

アジェンダ

01 AI レディとは何か

「読める」から「アウトカムを生む」へ

02 立ちはだかる2つの壁

AI-Ready から AI エージェント・レディへ

03 壁①：膨大性

PDF・XBRL・HTML・画像をどう読み解くか

04 壁②：時系列

本当に AI エージェントは時系列を理解しているか

05 その先、AI-Ready から AI エージェント・レディへ

① AI レディの再定義

アウトカム（リターン）起点で考える



② 2つの壁

「読める」の先にある落とし穴



③④ 壁を越える解

膨大性 × 時系列



⑤ スーパーヒューマン

人を超える意思決定へ

01

AIレディとは何か


INDX ● 投資情報を AI-Ready にせよ

「AI レディ」の一般的な定義

まずは通説をおさらいする

- **アクセス可能** — API・DB で機械的に取得できる
- **品質** — 欠損・重複・表記ゆれが整っている
- **真実性** — 出所が明確で、正確かつ最新である
- **検索可能** — メタデータが付与され、探し出せる

通説では、品質・網羅性・ガバナンス等を満たせば「AI 利用に適す」とされる（Gartner）。



4 つの性質で「囲めば AI レディ」が通説

...では、これで本当に「十分」なのか？

AI レディの再定義

「読める」ではなく「アウトカムを生む」

AI レディ = データが AI を通じて**アウトカム**を生み出せる状態

必要条件 ≠ 十分条件

品質・網羅性・真実性は AI レディの**必要条件**。

だが、それだけでは**十分条件ではない**。
整ったデータが、そのまま**リターン**を生むわけではない。

律速はモデルよりデータ基盤

成否を分けるのはモデルの賢さより**データ基盤への投資の深さ**。AI-Ready なデータに支えられない AI プロジェクトの **60%** は 2026 年までに放棄される、と Gartner は予測する。

出典: Gartner 「AI-Ready Data」 (2025)

クオンツにとっての「アウトカム」とは

コスト削減も価値。だが本丸はリターン

① コスト削減（効率）

リサーチ時間の短縮、レポートの自動生成、人手の圧縮。

確実な価値だが、削れる量には
上限がある。

本丸へ

② リターン（アルファ）


より速く・広く・深い意思決定へ。

上限が開かれた、**クオンツの本丸。**

効率化は「使えるデータ」でも到達できる。しかし**リターン**に接続してこそ、データは真にAIレディである。

AI レディの全体像


多様な入力から、リターンというアウトカムまで



第 1 段階は**必要**。だが**リターン**につながって初めて**真の AI レディ**である。

AI レディは「連続体」である


成熟度ラダー：L0 → L3



多くの金融データは **L0～L1** で止まる。価値は「保有」から「解釈し、行動につなげる」へ移った。

L3へ至る道には「2つの壁」がある

ここから Part 02 へ



壁①：膨大性

PDF・XBRL・HTML・画像... **巨大すぎる**データを、いかにパースし検索可能にするか。

壁②：時系列

アクセスも API も分析もできる。だが AI エージェントは、時系列を本当に「**理解**」しているのか。

「読める」の**先**にこそ落とし穴。次の Part で、この**2つの壁**を一つずつ越えていく。

02

立ちはだかる2つの壁

INDX ● 投資情報を AI-Ready にせよ


「読める」の、その先へ

AI-Ready から AI エージェント・レディへ

- **AI-Ready** とは、データが**アウトカム (=リターン)** につながる状態 (Part 01)。
- だが「**読める・検索できる**」だけでは、まだ**人間が使う道具**にすぎない。
- ゴールは **AI エージェント**がデータを**自律的に使いこなす**状態 = **AI エージェント・レディ**。

ここで初めて壁が見える


「読める」から「使いこなす」への**段差**にこそ、越えるべき**2つの壁**が潜む。



「読める」と「使いこなす」の間には段差がある。

立ちはだかる2つの壁

多様な金融データ —— 壁① × 壁② —— アウトカム



2本の壁を越えて初めて、データは**アウトカム**に届く。

なぜ「落とし穴」なのか

解決済みに見えて、じつはまだ越えていない

「API もある・アクセス
できる・分析もできる」

→ 一見、解決済みに見える



しかし実態は ——
AI エージェントが本当
に使える状態ではない

- だから「壁はもう無い」と思い込む
—— これが最大の**落とし穴**。

壁②はさらに深い落とし穴

壁①（膨大性）は「大きすぎて明らかに
難しい」と見える分、まだ気づける。

だが壁②（時系列）は ——
フレームワークはあるのに、**一個一個
がつながっていない**。「できているつも
り」で素通りしてしまう。

→ 次は **Part 03 = 膨大性** / **Part 04 = 時系列** の
順に崩す。

03

壁①：膨大性をどう 読み解くか

INDX ● 投資情報を AI-Ready にせよ

壁①：膨大性

金融文書は「明らかに大きすぎる／構造が壊れている」

- 有価証券報告書・決算短信・目論見書……金融の一次情報は **PDF・XBRL・HTML・スキャン画像** が入り混じる。
- 数百ページ、ネストした表、注記・脚注に散る数値。**人が全部を読み切ることは不可能**。
- しかも LLM に **生のまま** 渡すと、構造が壊れて数値を取り違える。




バラバラな一次情報を、そのまま流し込むと壊れる。

「読める」だけでは足りない。まず**読み解ける形**にする必要がある。

証拠：生のLLMは金融文書で崩れる

ボトルネックはモデルではなく、データ準備




■ 生のまま ■ 前処理・検証を入れた整った設計

- **ネスト表 PDF**：GPT-4o は前処理なしで **56%**→専用パイプラインで **76%**。
- **FinanceBench**：
GPT-4-Turbo + 検索でも **81%**の質問が誤答・回答拒否。
- **Fin-RATE**：企業横断比較で精度が **23.91%**→**1.27%**へ崩壊（検索設計の失敗）。
- **AUDITFLOW**：検証層を外すと **82%**→**18%**へ崩壊。

一つの解：AI-Ready パイプライン

raw 文書を「読み解ける」状態へ変換する



設計の勘所


表・数値・脚注の**意味を保ったまま**構造化することが、後段の検索と推論の精度を決める。

検索アーキテクチャ

階層型・グラフ型の検索は、フラットなベクトル検索を上回る。文書の構造を捨てないことが鍵。

高精度＝最善とは限らない

コストのパレートフロンティアで選ぶ



	反射型	階層型
F1	0.943	0.924
\$/文書	0.430	0.148

100 万文書規模なら

コスト差は**\$282,000**。リーダーボードの精度だけで調達を決めると、**TCO を見誤る**。

規模に応じた設計が TCO（総保有コスト）を左右する。

F1 は僅差 (0.943 vs 0.924) だが、コストは約 3 倍違う。


投資情報を AI-Ready にせよ

出典: Benchmarking multi-agent 2026

壁①: 膨大性をどう読み解くか

接続はコモディティ化する

価値は「持つこと」から「解釈・行動」へ



価値の移動：接続から解釈へ

データへの**接続**はコモディティ化した。残る差別化は——

- データを**解釈**する力
- 文脈を与え**文脈化**する力
- **行動（アウトカム）につなぐ力**

主要ベンダーが MCP を提供し、AI から**標準接続**できる。

出典: Bloomberg / LSEG / FactSet / Daloopa の MCP 提供 (2025~2026)

壁①：膨大性 — まとめ

押さえるべき3点

1. 膨大性は**前処理・構造化・検索設計**で越えられる。生の LLM 任せでは崩れるが、パイプラインで **56%→76%** のように取り戻せる。
2. ボトルネックは**モデル能力ではなくデータ準備**。モデルを替える前に、データを読み解ける形にする。
3. 差別化は**接続ではなく解釈**。MCP で接続がコモディティ化したいま、価値は解釈・文脈化・行動へ移る。

壁①は **AI-Ready パイプライン** で越えられる。次は壁②：時系列。

04

壁②：時系列は本当にAIレディか

INDX ● 投資情報を AI-Ready にせよ

一見、時系列は「もうAIレディ」に見える

株価・金利・出来高… アクセスも分析もできる

- 株価・金利・為替・出来高——数値の時系列は、いま最も**整備が進んだ**データに見える。
- だから素朴には、こうってしまう。

よくある見方

「アクセスもできる、API もある、分析もできる。
時系列は**もう解決済み**なのでは？」

✓ **アクセスできる**
ヒストリカルデータが揃う

✓ **API がある**
J-Quants 等で機械的に取得

✓ **分析もできる**
可視化・統計量・バックテスト


✓ **LLM も読める**
数列をトークンとして入力可

「できていること」は多い。だが十分だろうか。

【落とし穴】本当に「理解」しているのか

読めること $\neq$ 統計的構造を内在化していること

- LLM は時系列をトークン列として
は読めるが、
非定常性・レジーム変化・データ
リーク (先読み)・因果を内在化し
ていない。
- 学習カットオフ以降に評価をずら
すだけで——



ベンチのアルファは脆い

77 件の LLM トレーディング研究のレビューで、取引コストを明示モデル化したのは**わずか 1 件**、時間整合的で再現可能な評価は**わずか 2 件**のみ。

学習カットオフ以降に評価をずらすと年率アルファ **+20.73%**
→ **-1.04%**。

出典: Look-Ahead-Bench, 2026 / Agentic trading review, 2026

なぜ難しいか：意味は「数列」に宿らない

時系列の意味は、パラメータ・モデル・因果構造に宿る

- 時系列の意味は「数値の羅列」そのものではなく、その背後の**パラメータ・モデル・因果構造**に宿る。
- LLM はテキストとしては処理できても、**統計的構造を理解しているわけではない。**

壁①と同じ罠が、より深い形で


壁①の教訓「**読める ≠ 使える**」が、時系列では**さらに顕著**に立ちはだかる。



LLM は表層のトークン列に届くが、意味の在処には届かない。

解：専門AIエージェントがモデルを解釈し、LLMへブリッジする

時系列 → 専門エージェント → 解釈 → ブリッジ → アウトカム



「数列」ではなく**解釈済みの構造**を、LLM に手渡す

それでも、まだAIレディではない

フレームワーク（部品）はあるが、一個一個つながっていない

- モデルも、エージェントも、検証手法も——**部品（フレームワーク）は揃っている。**
- しかし、それらが**一個一個つながっていない。**
これが壁①より**深い落とし穴。**
- 解決には、意思決定まで**一気通貫**でつなぎ、**検証層**を組み込むことが要る。

実装条件：検証層を組み込む

- **棄権**——「答えてはいけない状況」を検知する能力。
- グラフ・記号での**経路検証**（FinChain / GBFR）。
- **反事実・因果**を組み込んだ検証（FinCARE ほか）。

金融 AI の信頼性は、当てる力より「**答えない力**」に宿る。

壁②まとめ：時系列は「理解」でつまずく

壁②の要点

- 時系列は「アクセスできる」と「理解している」のがまったく別物。学習カットオフをまたぐだけで、アルファは **+20.73% → -1.04%** へ消える。
- 解は、**専門 AI エージェント** が統計・DL・時系列モデルを道具として実行し、その **パラメータと意味を解釈** して、**LLM が読める形にブリッジ** すること。
- ただし部品はまだ **つながっていない**。
棄権・反事実・因果 を組み込んだ検証層こそ、実装の条件。

時系列の AI レディ化とは、**解釈と検証を一気通貫でつなぐこと**

05

その先へ：スーパー ヒューマンな意思 決定

INDX ● 投資情報を AI-Ready にせよ

2つの壁を越えた先に

多様データ × 膨大性突破 × 時系列理解 × アウトカム最適化

AI エージェント・レディの完成形 —— データがそのままアウトカムを駆動する



一気通貫でつながって、はじめて「使いこなす」

Part 01 の一枚の図が、2つの壁を越えて完成する。

スーパーヒューマンな意思決定へ

究極の状態＝人間を超える意思決定は、データ基盤の上に立つ

実運用に到達した AI-Native ファンド

- **Bridgewater** (AIA Labs) : 実資本を運用し初年度**+11.9%**
- **Renaissance** (Medallion) : 設立来**年率+39.9%**
- **QRT** (Qube) : 2025 年 主力ファンドで約**+30%**

いずれも土台は**データ基盤への長年の投資**。

逆に —— 基盤なきエージェント導入

基盤投資を伴わない「AI エージェント導入」は、DeepFund 等の独立検証で**純損失・性能ギャップ**に直面しやすい。

差別化は**データを持つこと**から**どう解釈し行動に結びつけるか**へ。

モデルの進歩を待つな。それを意思決定に変える基盤を、いま積む。

まとめ：2つのメッセージ

きょう持ち帰ってほしいこと

メッセージ①：AI レディの本質

AI-Ready とは「**アクセスできる**」ことではない。


データが**アウトカム（＝リターン）**につながっている状態こそが本質。



メッセージ②：2つの壁を越える


そこへ至る道には**2つの壁**がある——

壁①膨大性・**壁②時系列**を越えて、**AI エージェント・レディ**へ。



INDXのスタンス

2つの壁に対する、ひとつの解を



私たちがやること

私たちは、この**2つの壁**に対する**ひとつの解**を示したい——膨大な金融文書を読み解き、時系列を専門エージェントで解釈して LLM へブリッジし、そのすべてを**アウトカム (=リターン)** へつなぐ。

投資情報を **AI-Ready** にせよ

読める、の先へ —— **人を超える意思決定**のために。

ありがとうございました

ご質問・ディスカッション歓迎です (Q&A)

いとう @ INDX

お問い合わせ：**i@indx.jp**

マケデコ (market-api.dev) / J-Quants コミュニティ